

Servicio Nacional de Aprendizaje

SENA

GUIA DE APRENDIZAJE Nº 1

Programa

Procesamiento de datos para modelos de inteligencia artificial

Trimestre I

Ficha

3602991

Autores

Juana Virgelina Corrales Rico

Laura Natalia Becerra Tirano

Tabla de contenido

1. Introducción… ……3
2. Diferencias Estructurales CSV vs. XLS vs. XLSX ……..…..4
3. Desarrollo del Esquema del tránsito seguro de la información…….…..5
4. Conclusión analítica…….…...6
5. Actividades de contextualización e identificación de conocimientos…….7
6. Una tabla estructurada 30 variables……..…8
7. AUDITORÍA TÉCNICA DE DATASETS…….11
8. Diccionario de Datos ……..16
9. Conclusiones ……...18
10. Referencias……..19

Introducción

El documento constituye una guía de aprendizaje orientada a comprender el valor estratégico de los **datos, su correcta gestión, los formatos de almacenamiento y el impacto ético** en los procesos de toma de decisiones a nivel gubernamental y gerencial.

Ejes Temáticos y Actividades Principales:

- **Análisis de Formatos y Fallos de Integridad:** Se examinan las diferencias estructurales entre los archivos de texto plano (**CSV**), las hojas de cálculo heredadas (**XLS**) y los formatos modernos (**XLSX**), destacando sus límites de filas y columnas. Esto se complementa con el estudio de un caso real (*Public Health England*), donde un límite de almacenamiento obsoleto causó la pérdida silenciosa de casi 16,000 registros de salud pública.
- **Flujo Seguro de Información:** Se propone un esquema secuencial óptimo para el tránsito de datos desde los laboratorios (origen) hasta los tableros de control (destino), justificando el uso de bases de datos relacionales y formatos adecuados para prevenir la corrupción de la información.
- **Ética y Responsabilidad Profesional:** La guía enfatiza que el rigor técnico del analista de datos no es opcional, ya que los errores en el procesamiento repercuten directamente en políticas públicas y en la vida de las personas.
- **Auditoría Técnica y Gestión de Datos:** El equipo selecciona el eje de **Seguridad** y utiliza conjuntos de datos secundarios obtenidos de *Kaggle* y *Datos Abiertos Bogotá* (relacionados con delitos, rendimiento académico y seguridad nocturna para las mujeres). Sobre estos datasets, realizan una auditoría técnica para detectar y documentar inconsistencias comunes —como datos faltantes, duplicados, valores sucios y problemas de estandarización—, culminando con la creación de un **diccionario de datos** formal para asegurar la calidad y trazabilidad de la información.

2.1.1 Actividades a Desarrollar

1) Diferencias Estructurales CSV vs. XLS vs. XLSX y Análisis de Fallo

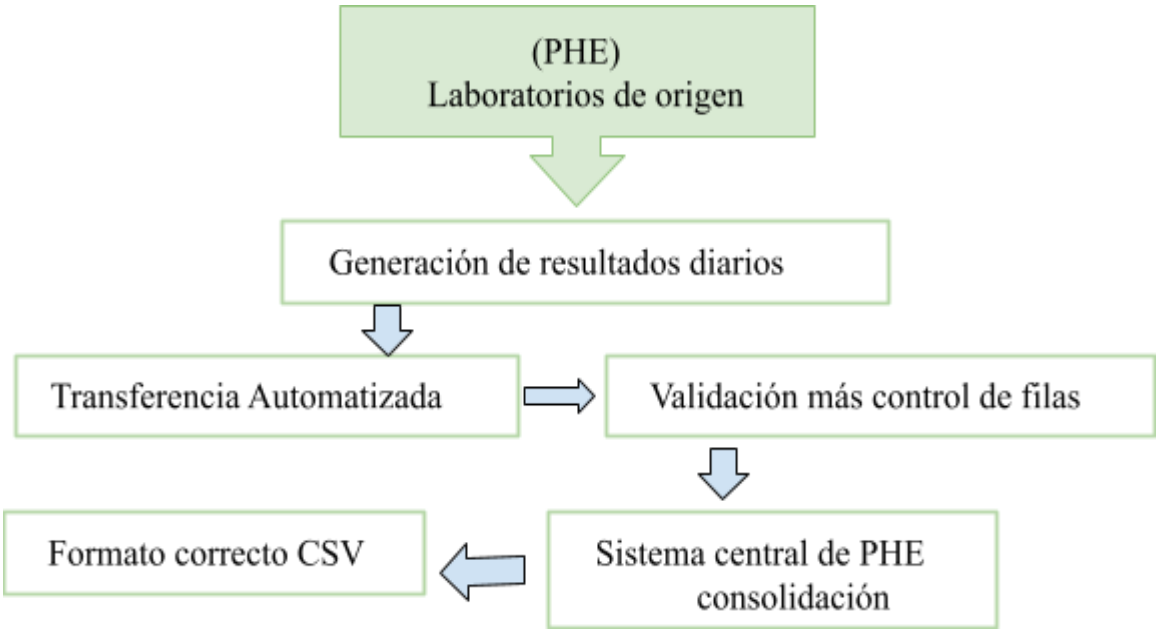
Resumen Comparativo de Formatos de Archivos de Datos

Característica	CSV	XLS (Heredado)	XLSX (Moderno)
Tipo de archivo	Texto plano	Binario propietario	ZIP / XML comprimido
Límite de filas	Ilimitado (según disco/RAM)	65,536 filas	1,048,576 filas
Límite de columnas	Ilimitado	256 columnas	16,384 columnas
Múltiples hojas	No (solo 1 tabla)	Sí	Sí
Soporte de fórmulas	No (guarda valor final)	Sí	Sí
Formatos y colores	No	Sí	Sí
Macros (VBA)	No	Sí	No (requiere .xlsm)

¿En qué punto exacto falló la integridad de los datos?

Falló en la Etapa 2: Transferencia Automatizada. Según el caso expuesto en la guia, los laboratorios enviaban correctamente la información en archivos CSV, pero el proceso automático de Public Health England (PHE) importaba dichos archivos de CSV a una plantilla obsoleta en un formato XLS. Cuando el acumulado de pruebas superó el límite de 65,536 filas, el sistema tuvo un fallo silencioso que no se detecto y cortó el excedente de información y perdió 15,841 registros sin generar ninguna alerta de error. Esto afecto gravemente el principio de integridad y trazabilidad del dato.

2) Desarrollo del Esquema del tránsito seguro de la información.



Este es el esquema de como DEBIÓ hacerse para no perder los 15.841 casos:

Justificación del flujo seguro:

1. **Laboratorios Transferencia: mantener CSV.** El csv es el formato más seguro para el origen porque no tiene límite de filas, no se corrompe con formatos y es legible por cualquier sistema. Es ideal para volúmenes masivos diarios.
2. **Transferencia sistema central: NO usar Excel.** La consolidación debió hacerse directamente en una base de datos manteniendo el procesamiento nativo en filas (ej: si llegan 80.000 registros, que el sistema verifique que 80.000 se cargaron). Está prohibido usar .XLS por su límite obsoleto.
3. **Sistema central Tablero: Usar XLSX o Base de Datos.**
   Si los analistas necesitan excel, se debe usar obligatoriamente .XLSX (1.048.576 filas), que si soportaban el volumen del pico pandémico. Lo ideal es que Dashboard (Power Bi /Tableau) lea directo de la base de datos, sin pasar por Excel.
   Con este flujo se garantiza la preservación de los casi 16.000 registros.

Conclusión analítica

El caso de PHE muestra que un error técnico aparentemente menor, como desconocer la diferencia entre .xls y xlsx, se convierte en un error ético y de salud pública.

El analista de datos no solo es un operador de ofimática, es el primer eslabón de la cadena de toma de decisiones. su desconocimiento técnico provocó que:

1) Los tableros mostraron una falsa disminución de casos, llevando al gobierno a asumir que las restricciones funcionaban.
2) 50.000 contactos estrechos no fueran rastreados (Halliday et al., 2020), acelerando la propagación del virus.

La responsabilidad ética del analista es conocer los límites de sus herramientas y configurar alertas de integridad. A nivel gerencial / gubernamental, la responsabilidad es no tomar decisiones críticas basadas en un solo tablero sin auditar la calidad del dato. Como sostuvo el secretario de salud en House of Commons (2020, p. 625), los positivos si fueron notificados para aislarse, pero el daño en el rastreo ya estaba hecho. El conocimiento técnico, por tanto, no es opcional : es una obligación ética cuando de ello depende vidas humanas y políticas públicas.

El caso demuestra que la ignorancia técnica es una falta ética. El analista desconocía un límite básico del formato XLS desde 1987. Ese desconocimiento se tradujo en 50.000 contactos no rastreados y aceleración de la pandemia. A nivel gerencial, las decisiones dependen de la integridad del dato; si el técnico no garantiza el formato, el directivo decide sobre una realidad falsa. Conocer los límites de las herramientas es proteger vidas, no solo filas.

2.2 Actividades de contextualización e identificación de conocimientos

Tema escogido: Eje de Seguridad

Escogimos el **eje de seguridad** para la extracción de *datasets* porque constituye un pilar estratégico indispensable por tres razones clave:

- **Protección y Privacidad:** Mitiga vulnerabilidades y garantiza el cumplimiento de normativas de protección de datos (privacidad y confidencialidad).
- **Calidad y Confiabilidad:** Asegura que los datos estén libres de manipulaciones, sesgos maliciosos o inyecciones que puedan alterar los análisis o modelos.
- **Prevención Proactiva:** Permite identificar vectores de ataque y brechas latentes antes de que afecten el sistema o a los usuarios finales.

En conclusión: Priorizar la seguridad garantiza que la información extraída sea confiable, ética, legal y técnicamente robusta. Para realizar esta guía se utilizaron fuentes de Datos Secundarias que son Kaggle y Datos Abiertos Bogotá ya que son de fácil acceso para que los ciudadanos los consulten y utilicen a través de plataformas que los centralicen. También por que estos datos no son recolectados por cuenta propia. Especificando para cada uno: nombre del dataset, portal de alojamiento y enlace (URL) de acceso.

Datasets:

- Nombre del Dataset : Delitos-Colombia
- Autor: Leonardo Arias Alemán
- URL : https://www.kaggle.com/datasets/leonardoariasalemn/delitos-colombia

- Nombre del Dataset :Puntos de evaluación nocturna para las mujeres. Bogota D.C
- Autor: Secretaría Distrital de la Mujer URLhttps://datosabiertos.bogota.gov.co/dataset/puntos-de-evaluacion-de-seguridad-nocturna-para-las-mujeres-bogota-d-c-ano-2016

- Nombre del Dataset: Rendimiento Académico
- Autor : Marilú Ramírez López
- URLhttps://www.kaggle.com/datasets/marilramrezlpez/rendimiento-estudiantil

Una tabla estructurada 30 variables:

Matriz de Clasificación Estadística de Variables Extraídas de los Datasets

No.	Variable / Columna	Tipo Estadístico	Subcategoría	Descripción Breve
1	Iluminación	Cualitativa	Ordinal	Nivel de alumbrado observado (Alta, Media, Baja).
2	Visibilidad	Cualitativa	Ordinal	Percepción del nivel de visibilidad del entorno.
3	Presencia de personas	Cuantitativa	Discreta	Conteo del número de personas en el área.
4	Seguridad	Cualitativa	Ordinal	Nivel estimado de seguridad (Seguro, Inseguro).
5	Estado del Sendero	Cualitativa	Ordinal	Estado físico del camino peatonal.
6	Transporte	Cualitativa	Nominal	Tipo de transporte utilizado o disponible.
7	Presencia mixta	Cualitativa	Nominal	Evaluación de

				diversidad en el sector.
8	Índice de Seguridad	Cualitativa	Ordinal	Nivel de riesgo o seguridad (Alto, Medio, Bajo).
9	Dirección	Cualitativa	Nominal	Nomenclatura urbana de la ubicación.
10	Nombre de localidad	Cualitativa	Nominal	Nombre oficial de la localidad.
11	Tipo de crimen	Cualitativa	Ordinal	Clasificación según la gravedad del delito.
12	Delito	Cualitativa	Ordinal	Categorización legal de la infracción.
13	Tipo de Arma	Cualitativa	Nominal	Elemento utilizado en el delito.
14	Departamento	Cualitativa	Nominal	Entidad territorial (orden alfabético).
15	Municipio	Cualitativa	Nominal	Entidad municipal (orden alfabético).
16	Género	Cualitativa	Nominal	Género de la víctima o registrado.
17	Rango de edad	Cualitativa	Ordinal	Intervalos categorizados de edad.
18	Fecha	Cuantitativa	Discreta	Fecha del evento

				expresada numéricamente.
19	Cantidad	Cuantitativa	Discreta	Número total de casos o registros.
20	Estudiante	Cuantitativa	Discreta	Identificador o número de estudiante.
21	Edad	Cuantitativa	Discreta	Edad expresada en años cumplidos.
22	Nivel de Inglés	Cualitativa	Ordinal	Grado de dominio del idioma.
23	Horas de Estudio Semana	Cuantitativa	Continua	Tiempo dedicado al estudio semanal.
24	Asistencia porcentaje	Cuantitativa	Continua	Porcentaje de asistencia registrado.
25	Participación Actividades	Cualitativa	Nominal	Valor booleano (Verdadero / Falso).
26	Promedio Calificaciones	Cuantitativa	Continua	Puntaje académico acumulado.
27	Nivel Estrés	Cualitativa	Ordinal	Grado de estrés (Alto, Medio, Bajo).
28	Método de Estudio principal	Cualitativa	Nominal	Estrategia de aprendizaje utilizada.
29	Proyecto final entregado	Cualitativa	Nominal	Estado de entrega

				(Booleano).
30	Nota Final	Cuantitativa	Continua	Calificación cuantitativa definitiva.

2.3 . Datasets seleccionados :

- Nombre del Dataset: Rendimiento Académico
- Nombre del Dataset :Puntos de evaluación nocturna para las mujeres. Bogota D.C

AUDITORÍA TÉCNICA DE DATASETS (Rendimiento Académico)

Figura 1. Inconsistencia

D
horas_estudio_semana
24
19
10.1
8.8
10
19.8
17.2
6.3
6
4.3
17.2
19.6

• ¿Cual es el problema ?

Falta de estandarización en los datos o también una Ambigüedad en las unidades de medida

• ¿Cómo se detectó ?

Se comparó el nombre del dataset (Horas de estudio) pero nos dimos cuenta que el formato del tiempo no es muy claro

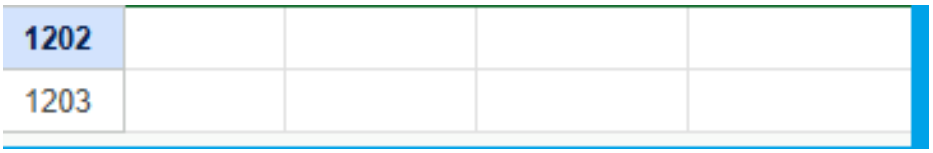
• ¿Por qué cree que se trata de un problema?

En las celdas no especifican si son Horas , Minutos o Segundos, lo que puede generar un error ya que no está en formato horario más explícito.

Se podría malinterpretar como 19 horas y 6 segundos o 19 horas y 6 minutos .

lo correcto sería: **19:06:00**

Figura 2. Inconsistencia



• ¿Cual es el problema ?

Error de datos faltantes (Missing Data) También es un problema de completitud y de integración de los datos .

• ¿Cómo se detectó ?

Se revisó el total de estudiantes y notamos inconsistencias cuando filtramos y dos de ellos no tenían datos en ninguna de las celdas

• ¿Por qué cree que se trata de un problema?

Al no eliminarse las filas se sesga la información sobre cuántos estudiantes realmente hay entonces podría causar un desfase en estadísticas y también quedarían registros huérfanos.

Figura 3. Inconsistencia

D G	E
Pomedia_Calificaciones	asistencia_porcentaje
6.98	88.5
9.87	92.9
9.83	73.8
6.99	86.9
7.39	85
9.58	94.1
9.87	96.7
7.77	65.4
7.28	88.6
8.1	66.8
8.75	84.2
7.09	75.1
8.95	75.7
6.21	77.4
6.2	86.7
7.55	76.7
7.41	90.6
7.26	79.2
7.96	67.4
	92.4
	75
	80.1
	89
	76.6

- **¿Cual es el problema ?**

Error de formato o formato inconsistente

- **¿Cómo se detectó ?**

Filtramos y encontramos que hay unos promedios de calificaciones que no siguen el mismo formato que la mayoría

- **¿Por qué cree que se trata de un problema?**

En la columna “promedio calificaciones” observamos una serie de números Decimales y en su mayoría No hacen aproximaciones , en un dato inconsistente ya que la información no está estandarizada correctamente y uniformemente

DATASETS (Puntos evaluacion seguridad nocturna)

Figura 4. Inconsistencia

	A	B	C	D	E	F	G	H	I
	ID Punto	Iluminac	¿Qué veo?	Visibilidad	Presencia de	Segurid	Estado d	Transpor	Presencia mixta
616	615	Suficiente	Bastante visible	No miran	Pocas personas	Ninguna	Bueno	Muy Cerca	No hay diversidad
617	616	Suficiente	Bastante visible	Algunos miran	Bastantes perso	Ninguna	Bueno	Muy Cerca	No hay diversidad
618	617	Suficiente	Bastante visible	Algunos miran	Bastantes perso	Ninguna	Bueno	Muy Cerca	No hay diversidad
619	618	Suficiente	Bastante visible	Muchos miran	Bastantes perso	Ninguna	Bueno	Muy Cerca	Hay poca diversidad

	J	K	L	M	N	O
	Índice (	Dirección	C	Nombre	Coordenada X	Coordenada Y
	Medio	Hospitales A - 3 o 6, Bogotá, Colombia	3	Santa Fe	-7,408,449,999,990	458,999,999,985
	Alto	Hospitales B - 4 o 6, Bogotá, Colombia	3	Santa Fe	-7,408,409,999,960	459,050,000,086
	Alto	Hospitales B - 4 o 6, Bogotá, Colombia	3	Santa Fe	-7,408,409,999,960	459,050,000,086
	Alto	AK 10 - Cl 2, Bogotá, Colombia	3	Santa Fe	-7,408,320,000,020	459,160,000,086

¿Cual es el problema ?

Datos duplicados (Duplicate Data)

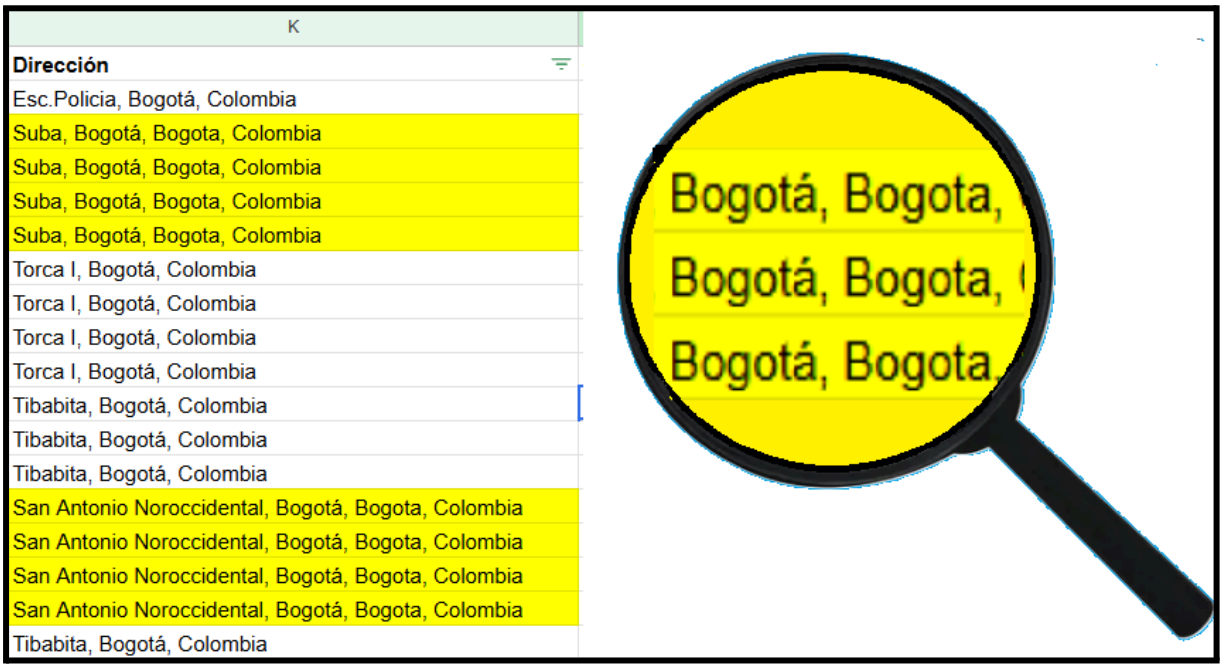
- **¿Cómo se detectó ?**

Filtramos las variables y encontramos duplicados exactos

- **¿Por qué cree que se trata de un problema?**

Se filtraron las celdas y se encontraron coincidencias en todas las variables, puede generar errores de consulta de archivos . También puede generar un sesgo estadístico.

Figura 5. Inconsistencia



K
Dirección
Esc.Policia, Bogotá, Colombia
Suba, Bogotá, Bogota, Colombia
Suba, Bogotá, Bogota, Colombia
Suba, Bogotá, Bogota, Colombia
Suba, Bogotá, Bogota, Colombia
Torca I, Bogotá, Colombia
Torca I, Bogotá, Colombia
Torca I, Bogotá, Colombia
Torca I, Bogotá, Colombia
Tibabita, Bogotá, Colombia
Tibabita, Bogotá, Colombia
Tibabita, Bogotá, Colombia
San Antonio Noroccidental, Bogotá, Bogota, Colombia
San Antonio Noroccidental, Bogotá, Bogota, Colombia
San Antonio Noroccidental, Bogotá, Bogota, Colombia
San Antonio Noroccidental, Bogotá, Bogota, Colombia
Tibabita, Bogotá, Colombia

¿Cual es el problema ?

Datos Sucios

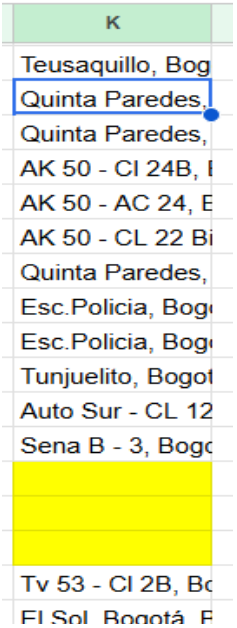
- **¿Cómo se detectó ?**

Buscamos caracteres en la barra superior y encontramos dos inconsistencias.

- **¿Por qué cree que se trata de un problema?**

Datos con faltas de ortografía, se repite la palabra “Bogotá,Bogotá” También cabe aclarar que para pasar los Dataset a PYTHON o bases de datos SQL ,MYSQL,ORACLE,etc; **No pueden tener caracteres especiales**

Figura 6. Inconsistencia



K
Teusaquillo, Bog
Quinta Paredes,
Quinta Paredes,
AK 50 - Cl 24B, I
AK 50 - AC 24, E
AK 50 - CL 22 Bi
Quinta Paredes,
Esc.Policia, Bog
Esc.Policia, Bog
Tunjuelito, Bogot
Auto Sur - CL 12
Sena B - 3, Bogc
Tv 53 - Cl 2B, Bc
El Sol, Bogotá, E

¿Cual es el problema ?

Error de datos faltantes (Missing Data) Pero como no es una fila completa de datos faltantes también se califica como Esporádicos o aislados (Isolated Missing Values).

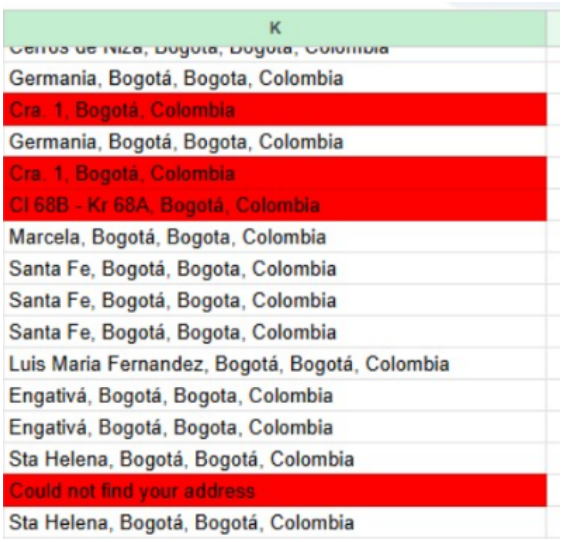
- **¿Cómo se detectó ?**

Se revisó en filtrar y se encontraron dos celdas vacías de una misma variable

- **¿Por qué cree que se trata de un problema?**

En este caso hay celdas sin información esto ocasiona una afectación al interrumpir las funciones y estadísticas en Machine Learning (Aprendizaje Automático) que no recibe las celdas vacías o como lo explicado en las exposiciones Valores nulos.

Figura 7 . Inconsistencia



¿Cual es el problema ?

Outliers (Datos atípicos)

- **¿Cómo se detectó ?**

Al revisar los filtros de nombres encontramos direcciones inexistentes

- **¿Por qué cree que se trata de un problema?**

Puede generar un error al mapear las direcciones.

2.4. Diccionario de Datos:

Diccionario de Datos del Dataset de Seguridad Nocturna

Nombre Original	**Nombre Sugerido**	**Clasificación Estad.**	**Tipo Técnico**	**Descripción Semántica**	**Formato / Valores**
ID Punto	id_punto	Cuantitativa Discreta	Entero	Identificador único asignado al punto de evaluación.	Número entero
Iluminación	iluminacion	Cualitativa Ordinal	Cadena texto	Grado de alumbrado público observado.	Brillante, Suficiente, Insuficiente, Oscuro
¿Que veo?	que_veo	Cualitativa Ordinal	Cadena texto	Grado de visibilidad panorámica percibida.	Visibilidad total, Bastante visible, Poco visible
Visibilidad	visibilidad	Cualitativa Ordinal	Cadena texto	Percepción de personas atentas al entorno.	Muchos miran, Algunos miran, No miran
Presencia personas	presencia_personas	Cualitativa Ordinal	Cadena texto	Afluencia de peatones en el sector.	Bastantes personas, Pocas personas, Desierto
Seguridad	seguridad	Cualitativa Ordinal	Cadena texto	Percepción de vigilancia institucional.	Alta, Media, Baja, Ninguna
Estado del Sendero	estado_sendero	Cualitativa Ordinal	Cadena texto	Condición física de la vía peatonal.	Bueno, Regular, Malo

Índice Seguridad	indice_seguridad	Cualitativa Ordinal	Cadena texto	Valoración global del nivel de riesgo.	Alto, Medio, Bajo
Dirección	direccion	Cualitativa Nominal	Cadena texto	Ubicación o nomenclatura urbana.	Texto alfanumérico
Nombre Localidad	nombre_localidad	Cualitativa Nominal	Cadena texto	Nombre de la localidad oficial.	Texto (Nombre propio)
Código Localidad	codigo_localidad	Cuantitativa Discreta	Entero	Código numérico político-administrativo.	Número entero (1 a 20)
Coordenada X	coordenada_x	Cuantitativa Continua	Decimal	Posición geográfica longitudinal.	Coordenadas planas (Metros)
Coordenada Y	coordenada_y	Cuantitativa Continua	Decimal	Posición geográfica latitudinal.	Coordenadas planas (Metros)
Transporte	transporte	Cualitativa Nominal	Cadena texto	Cercanía de paraderos de transporte.	Muy cerca, Cerca, Lejos, No disponible
Presencia mixta	presencia_mixta	Cualitativa Nominal	Cadena texto	Diversidad de género/edad en el espacio.	Hay diversidad, Poca diversidad, No hay

Conclusiones

La importancia de los formatos y herramientas son fundamentales para diferenciar entre un CSV, o un XLS que ya no se utiliza y un XLSX moderno. nos da la importancia del poder perder información masiva al no tener en cuenta lo anterior.o pudimos observar en el caso de las pruebas de COVID-19 en Inglaterra, donde se perdieron casi 16,000 registros por limitaciones de formato.

Desde un punto ético y analítico comprendimos que el rol del analista de datos va mucho más allá de usar herramientas ofimáticas. Un error en la limpieza o una mala interpretación de los datos puede llevar a los directivos o al gobierno a tomar decisiones erróneas que afectan directamente a la sociedad (como pasó con el falso descenso en la curva de contagios y el retraso en el rastreo de contactos). Por lo tanto, el rigor técnico es una obligación ética ineludible.

Auditar datos de calidad mediante la revisión de los datasets reales evidenciamos que los datos en bruto casi siempre vienen con fallas (celdas vacías, registros duplicados, datos sucios o mal formateados). Hacer una auditoría técnica y estructurar un buen diccionario de datos es fundamental para garantizar que la información sea limpia, confiable y apta para cualquier análisis o modelo futuro. y asi poder alimentar correctamente los futuros modelos de IA.

Referencias

Arias Alemán, L. (s. f.). Delitos-Colombia [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/leonardoariasalemn/delitos-colombia Datos Abiertos Bogotá. (s. f.). Portal de Datos Abiertos de la Ciudad de Bogotá D.C. https://datosabiertos.bogota.gov.co/ Datos Abiertos Colombia. (s. f.). Portal Único de Datos Abiertos del Estado Colombiano. https://www.datos.gov.co/ Kaggle. (s. f.). Data Science and Machine Learning Community Platform. https://www.kaggle.com/ Kelion, L. (2020, 5 de octubre). Excel: Why using an old format caused 15,841 COVID tests to be lost. BBC News. https://www.bbc.com/news/technology-54423988 Ramírez López, M. (s. f.). Rendimiento Académico [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/marilramrezlpez/rendimiento-estudiantil Secretaría Distrital de la Mujer. (2016). Puntos de evaluación de seguridad nocturna para las mujeres. Bogotá D.C. [Conjunto de datos]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/puntos-de-evaluacion-de-seguridad-nocturnapara-las-mujeres-bogota-d-c-ano-2016